

# 1. 데이터 전처리

데이터 정제 → 결측값 처리 → 이상값 처리 → 분석 변수 처리

## 2. 데이터 정제

결측값을 채우거나 이상값을 제거하는 과정을 통해 데이터의 신뢰도를 높이는 작업

### 절차

#### 1) 데이터 오류 원인 분석

원인) 결측값, 노이즈, 이상값

#### 2) 데이터 정제 대상 선정

#### 3) 데이터 정제 방법 결정

방법) 삭제, 대체, 예측값 삽입

## 3. 결측값 처리

↳ 입력이 누락된 값

### 결측값 종류

#### 완전 무작위 결측 (MCAR)

변수상에서 발생한 결측값이 다른 변수들과 상관이 없는 경우

#### 무작위 결측 (MAR)

누락된 자료가 특정 변수와 관련되어 일어나지만, 그 변수의 결과는 관계가 없는 경우

#### 비 무작위 결측 (MNAR)

이 두 가지 관측 (measurement)

누락된 값이 다른 변수와 연관 있는 경우

## 처리 절차

결측값 식별 → 결측값 부호화 → 결측값 대체

## 처리 방법

### 단순 대체법

결측값을 그럴듯한 값으로 대체하는 통계적 기법

완전 분석법, 평균 대체법, 단순 확률 대체법

### 다중 대체법

단순 대체법을  $m$ 번 대체를 통해  $m$ 개의 가상적 완전한 자료를 만들어서

분석하는 방법

대치, 분석, 결합

## 4. 이상값 처리

↳ 관측된 데이터 범위에서 벗어난 작은 값이나 큰 값

## 이상값 발생 원인

### 데이터 입력 오류

데이터 수집 과정에서 발생할 수 있는 에러

### 측정 오류

데이터 측정 과정에서 발생하는 에러

### 실험 오류

실험 조건의 통제되지 않은 경우 발생

방법 조인이 증가해서 인한 성능 저하

## 고의적인 이상값

자기 보고식 측정에서 나타나는 어려

## 표본 추출 어려

데이터 샘플링하는 과정에서 나타나는 어려

## 검출 방법

개별 데이터 관찰, 통계값, 시각화, 머신러닝, 마할라노비스 거리, LOF, iForest

## 처리 방법

## 삭제

이상값으로 판단되는 관측값을 제외하고 분석하는 방법

## 대체법

이상값을 평균이나 중앙값 등으로 대체

## 변환

극단적인 값으로 인해 이상값이 발생하면 자연로그를 취해서 값을 감소시키는 방법

## 박스 플롯 해석

사분위 수를 이용해서 제거하는 방법

## 분류

이상값이 많을 경우 사용하는 방법으로, 서로 다른 그룹으로 통계적인 분석을 실행하여 처리

## 5. 분석 변수 처리

↳ Feature) 데이터 모델에서 사용하는 예측을 수행하는 데 사용되는 입력 변수

## 변수 명칭

## 변수 유형

### 독립 변수

다른 변수에 영향을 받지 않고 종속 변수에 영향을 주는 변수  
연구자가 의도적으로 변화시키는 변수

### 종속 변수

다른 변수로부터 영향을 받는 변수

독립 변수의 변화에 따라 어떻게 변화하는지 연구하는 변수

### 차원 축소

여러 변수의 정보를 최대한 유지하면서 데이터 세트 변수의 수를 줄이는 탐색적 분석 기법

주성분 분석(PCA), 특이값 분해(SVD), 요인 분석, 독립성분분석(ICA), 다차원척도법(MDS)

### 파생 변수

기존 변수에 특정 조건이나 함수 등을 사용하여 재정의한 변수

단위 변환, 표현 형식 변환, 요약 통계량 변환, 변수 결합

### 변수 변환

불필요한 변수를 제거하고, 변수를 반환하며, 새로운 변수를 생성시키는 작업

단순 기능 변환, 비닝, 정규화, 표준화

